

UrbanStyle · Nädal 2

Andmekvaliteedi audit: mis peitub 5 116 korduse taga

Tooteanalüüsi osakond · Nikita Kolenkovski

Defektid on tuvastatud ja dokumenteeritud. Andmeid ei ole kustutatud.

Hüpotees, mida kontrollisin

ENNE

„5 116 korduvat rida on
duplikaadid — need tuleb
kustutada.”

PÄRAST KONTROLI

„Kordused ei ole omavahel
identsed. 783 rida ei tohi
kustutada.”


Kontrollisin, kas korduvate ridade SISU on sama — mitte ainult nende arvu.

Viis erinevat probleemi ühe sümptomi all

Kategooria	Rühmi	Ridu	Mis see tegelikult on
A • identsed	3 239	4 051	topeltimport — võib kustutada
B • ainult kuupäevaformaad	213	282	sama päev — võib kustutada
C • klient on / puudub	370	517	puudulik kirje — EI TOHI
D • summad vastandmärgiga	165	234	müük + tagastus — EI TOHI
E • erinevad päevad	26	32	eri sündmused — EI TOHI

Tõelisi duplikaate on 4 333, mitte 5 116. Ülejäänud 783 rida on kolm muud defekti.

Mida tohib kustutada



4 333

tohib kustutada

783

ei tohi puutuda

Käive: ühte õiget arvu ei ole

Naiivne aruanne

4 230 940 €

ainult ISO-kuupäevad, kordused alles

Kuupäevad parandatud

4 374 231 €

+143 292 € tuli tagasi aruandlusse

Pärast dedupliketsiooni

2,85 – 2,94 mln €

sõltub originaali valiku reeglist

Hajuvus 95 955 € sõltub sellest, millist rida loeme originaaliks — see on äriotsus, mitte tehniline valik.

Viis eeldust — kõik ümber lükatud

- sale_id on unikaalne võti → 4 013 rühma korduva võtmega
- korduvad read on identsed → 774 rühma erinevad sisu poolest
- sale_date on kuupäevatüüpi → tekst kahes formaadis
- puuduvad e-mailid on tühjad stringid → tõelised NULL-id
- linnanimed on ühtlustatud → 54 kirjapilti 12 linna kohta

Ükski neist ei oleks avastatud ilma sihipärase kontrollita.

Soovitus Toomasele

**Mitte kustutada kordusi enne,
kui iga rühm on liigitatud —
kolmandik neist ei ole duplikaadid.**

Kriitilisim domeen: müügiandmed. Juurpõhjus: sale_id ei ole unikaalne võti allikas.

Meil puudusid andmed: milline süsteem võtmeid genereerib ja miks neid taaskasutatakse.